

WSI – Raport z ćwiczenia 7

Modele bayesowskie

Karol Zalewski 319128

1. Wprowadzenie

Celem ćwiczenia była implementacja naiwnego klasyfikatora Bayesa oraz wykorzystanie go do stworzenia systemu klasyfikującego wiadomości SMS. Zadanie polegało na automatycznym rozpoznawaniu wiadomości typu „spam” oraz „ham” na podstawie zbioru danych SMS Spam Collection Dataset.

2. Założenia projektu

Naiwny klasyfikator Bayesa został zaimplementowany w oparciu o wzór:

$$\operatorname{argmax}_C P(C) \prod_i P(x_i|C)$$

Wiadomości tekstowe zostały przekształcone na postać liczbową (atrybuty dyskretne) przy pomocy klasy CountVectorizer. Wyeliminowano słowa, które występują w języku bardzo często (takie jak and, are, a) w celu zwiększenia efektywności.

W implementacji zastosowano wygładzanie Laplace'a (dodanie 1), aby uniknąć problemu zerowych prawdopodobieństw dla słów, które nie wystąpiły w zbiorze treningowym danej klasy.

Zamiast mnożenia bardzo małych prawdopodobieństw, zastosowano sumowanie ich logarytmów, co zapobiega błędom niedomiaru.


Ostatecznie jakość modelu oceniono za pomocą 5-krotnej walidacji krzyżowej.

3. Prezentacja wyników


Eksperyment przeprowadzono na zbiorze 5572 próbek, w których zidentyfikowano 8404 unikalne cechy (słowa). Wyniki klasyfikacji wyglądały następująco:

- Ogólna dokładność: 97.94%
- Precyzja (Spam): 0.91 - Jeśli model oznaczył wiadomość jako spam, to miał rację w 91% przypadków.
- Czułość (Spam): 0.93 - Model wyłapał 93% wiadomości spam, które znajdowały się w zbiorze.
- Precyzja (Ham): 0.99
- Czułość (Ham): 0.99

Wartości liczbowe odnoszące się do skuteczności klasyfikacji można zobaczyć na poniższej macierzy konfuzji:



Wyniki walidacji krzyżowej prezentują się następująco:



4. Wnioski

Uzyskana została dokładność na poziomie 98% zarówno w teście, jak i w walidacji krzyżowej. Potwierdza to, że naiwny klasyfikator Bayesa jest efektywny przy klasyfikacji tekstowej. Mimo uproszczenia polegającego na ignorowaniu zależności między słowami, dało się precyzyjnie odróżnić spam od wiadomości typu ham.

Wyniki 5-krotnej walidacji krzyżowej, zwizualizowane na wykresie słupkowym, wykazują dużą stabilność. Potwierdza to, że podział danych nie był przypadkowo szczęśliwy, a że model został poprawnie wytrenowany.

Mimo dużej dysproporcji w liczbie próbek (znaczna przewaga w liczebności wiadomości typu ham) model zdołał zachować wysoką jakość dla klasy spamu (precyzja i czułość na poziomie ponad 90%).